

Rapport d'Analyse

Consommation Electrique & Detection d'Anomalies

Analyse Machine Learning d'un foyer residentiel 2006 - 2010

2006-2010

Periode analysee

1 min

Granularite

1 433

Jours analyses

72 jours (~5%)

Anomalies detectees

4

Clusters K-Means

Pipeline: Data Cleaning -> Feature Engineering -> K-Means Clustering -> Isolation Forest

Realise par :

Zineb Bekkali

1. Contexte du Projet

Ce projet a pour objectif d'analyser la consommation électrique d'un foyer résidentiel afin de détecter des comportements anormaux, potentiellement révélateurs d'une fraude ou d'un vol d'électricité. Les données utilisées proviennent du dataset *UCI Individual Household Electric Power Consumption*, avec des mesures effectuées **toutes les minutes** sur la période **2006-2010**, couvrant 1 433 jours analysables.

Variables mesurees :

Global_active_power	Puissance active globale (kW) - quantité réelle d'énergie consommée
Voltage	Tension électrique (V) - valeur normale ~230-240 V
Global_intensity	Intensité électrique (A) - liée à la puissance par $P = U \times I$
Sub_metering_1	Cuisine : four, micro-ondes, lave-vaisselle (Wh)
Sub_metering_2	Buanderie : machine à laver, sèche-linge, réfrigérateur (Wh)
Sub_metering_3	Chauffage, chauffe-eau, climatisation (Wh)

2. Preparation des Donnees (Data Cleaning)

Le dataset original utilise le point-virgule (;) comme séparateur et encode les valeurs manquantes par le caractère "?". Trois problèmes principaux ont été identifiés et corrigés avant toute modélisation :

Probleme 1 - Type de colonne

Les colonnes numériques étaient lues comme du texte (type objet). Solution : conversion forcée via `pd.to_numeric(..., errors='coerce')`.

Probleme 2 - Valeurs manquantes

Les valeurs manquantes étaient codées "?". Solution : remplacement par `pd.NA` puis suppression des lignes incomplètes via `df.dropna()`.

Probleme 3 - Dimension temporelle

Date et heure stockées dans deux colonnes séparées. Solution : fusion en un index `DatetimeIndex` unifié, étape indispensable pour le resampling journalier.

3. Analyse Exploratoire (EDA)

3.1 Consommation moyenne journaliere

Les mesures minute sont agregees par jour via `resample('D').mean()`. La serie temporelle revele une **saisonnalite marquee** : la consommation est significativement plus elevee en hiver, avec un comportement global stable d'une annee a l'autre. Les pics atteignent 3+ kW en hivers froids, tandis que les etes oscillent autour de 0.5-1.5 kW.

Fig. 1 - Consommation moyenne journaliere (kW) 2007-2010

3.2 Distribution de la consommation

L'histogramme montre une distribution **fortement asymetrique (right-skewed)** : la tres grande majorite des mesures correspond a de faibles puissances (< 1 kW), avec une longue queue droite representant des pics eleves. Ce profil est typique d'un usage domestique normal - la plupart du temps les appareils sont en veille ou eteints.

Fig. 2 - Distribution de Global_active_power (histogramme, 50 bins)

3.3 Profil horaire d'une journee type - 24 fevrier 2007

L'analyse d'une journee specifique illustre le **profil horaire caracteristique** d'un foyer : activite matinale des 3h, pic principal entre 8h-10h correspondant au petit-dejeuner et a la preparation du depart, niveau bas en journee (foyer vide), puis reprise en soiree vers 18h-19h. Ce schema coherent constitue la **signature normale** d'une journee residentielle.

Fig. 3 - Profil horaire de consommation le 24 fevrier 2007

4. Feature Engineering

Pour alimenter les modeles de Machine Learning, les donnees minute sont **agregées par jour** afin de creer un vecteur de caracteristiques synthetiques representant chaque journee sous la forme d'un point dans un espace a 8 dimensions.

Categorie	Variables creees	Utilite
Consommation	Moyenne, Maximum, Ecart-type (global_active_power)	Quantifier le niveau et l'instabilite journaliere
Electricite	Tension moyenne, Intensite moyenne	Detecter les anomalies de reseau (V hors norme)
Sous-compteurs	Sub_metering_1, _2, _3 (moyennes)	Identifier les incoherences entre compteurs et total

4.1 Standardisation (StandardScaler)

Avant d'appliquer K-Means et Isolation Forest, toutes les variables sont **normalisees** via StandardScaler (moyenne = 0, ecart-type = 1). Cette etape est indispensable : sans normalisation, les variables a grande echelle (ex. tension ~230 V) domineraient artificiellement les distances euclidiennes.

$$\text{Formule de standardisation : } Z = (X - \mu) / \sigma$$

Interpretation : $Z > 0$ -> journee plus consommatrice que la moyenne | $Z < 0$ -> journee plus faible que la moyenne. Toutes les variables sont ainsi comparables independamment de leur unite.

5. Clustering K-Means

K-Means regroupe les journees en **K clusters** en minimisant la distance euclidienne entre chaque journee et le centre de son cluster. Chaque journee est representee comme un vecteur $J = [x_1, x_2, \dots, x_8]$ dans l'espace des 8 features.

$$\text{Distance euclidienne : } d(J, C) = \sqrt{(x_1 - c_1)^2 + (x_2 - c_2)^2 + \dots}$$

5.1 Methode du coude - Choix de K = 4

La methode du coude trace l'inertie (somme des distances au carre vers les centres) en fonction de K. La courbe montre un **ralentissement marque a partir de k = 4**, indiquant le nombre optimal de clusters. Au-dela, le gain marginal ne justifie pas la complexite supplementaire.

Fig. 4 - Methode du coude : inertie en fonction du nombre de clusters k

5.2 Resultats de la segmentation

Les 4 clusters obtenus correspondent a des profils de consommation distincts, du plus faible au plus intense. Le cluster 3 presente la variance la plus elevee, indiquant des journees a la fois intenses et instables - profil a surveiller en priorite.

Cluster	Description	Niveau de risque
0	Consommation moyenne	Faible
1	Consommation moderee	Faible
2	Faible consommation	Modere
3	Forte consommation + haute variance	Eleve

6. Detection d'Anomalies - Isolation Forest

L'algorithme **Isolation Forest** detecte les anomalies en exploitant le principe suivant : un point *anormal* est isolable en peu de coupures aleatoires dans l'espace des features, tandis qu'un point *normal* necessite beaucoup plus de coupures pour etre isole. L'algorithme construit une foret d'arbres de decision aleatoires et mesure la profondeur moyenne d'isolation de chaque journee.

Parametres utilises :

contamination	0.05 - hypothese : 5% des journees sont anormales
Resultat	72 anomalies detectees sur 1 433 jours (~5%), coherent avec le parametre
Score	decision_function() : score negatif = plus suspect ; permet un classement du plus au moins suspect
Labels	-1 = Anomalie / Jour suspect +1 = Jour normal

6.1 Tableau des jours les plus suspects

Le tableau ci-dessous presente les journees classees anomalies (label = -1), toutes appartenant au cluster 3 (forte consommation). Les scores d'anomalie negatifs indiquent le degre de suspicion - plus le score est bas, plus la journee est atypique.

Fig. 5 - Extrait du tableau des journees suspectes detectees par Isolation Forest

6.2 Comparaison visuelle : Jour suspect vs Jour normal

La confrontation visuelle des deux journees du 16 et 17 decembre 2006 illustre parfaitement la difference entre un profil **anormal** et un profil **normal**. Le jour suspect presente une consommation **anormalement elevee des le debut de nuit** (17h-18h), avec des oscillations erratiques et une absence de la structure journaliere habituelle. Le jour normal, lui, presente les pics matinaux et de soiree attendus.

Fig. 6a - Jour suspect detecte : 2006-12-16

Fig. 6b - Jour normal de reference : 2006-12-17

Pourquoi le 16/12 est-il suspect ?

- **Consommation anormalement elevee la nuit** : pics entre 5 et 8 kW des 17h, valeurs inhabituelles pour un foyer en soiree
- **Oscillations erratiques et non naturelles** : fluctuations rapides sans pattern coherent (coupures frequentes ou comportement instable)
- **Absence de structure journaliere** : pas de creux diurne ni de montee progressive du matin
- **global_active_power_std eleve** : grand ecart-type signalant une instabilite anormale sur la journee

7. Limites & Pistes d'Amelioration

7.1 Limites de l'approche actuelle

Les anomalies identifiees sont des **anomalies statistiques** et ne correspondent pas necessairement a des fraudes reelles. Des faux positifs sont possibles dans les situations suivantes :

- Consommation hivernale elevee due au chauffage electrique - comportement legitime mais statistiquement atypique
- Presence de visiteurs ou d'appareils temporairement puissants (chantier, evenement)
- Pannes ou dysfonctionnements de capteurs generant des valeurs aberrantes
- Absence de variables contextuelles (meteo, jour de semaine) qui expliqueraient certains ecarts

7.2 Pistes d'amelioration

Variables temporelles	Integrer le jour de la semaine, le mois, la saison pour capturer la saisonnalite et reduire les faux positifs hivernaux
Donnees meteo	Ajouter la temperature exterieure comme feature - correlee directement au chauffage electrique
PCA	Reduction de dimensionnalite pour ameliorer la visualisation des clusters en 2D/3D
load_factor	Creer un indicateur avance : $\text{load_factor} = \text{mean} / \text{max}$, mesurant l'utilisation relative
Comparaison cluster	par Analyser systematiquement les profils suspects vs normaux au sein de chaque cluster
Seuil adaptatif	Ajuster dynamiquement le parametre contamination selon la saison pour eviter les biais hivernaux

8. Conclusion

Ce projet a permis de developper une **pipeline complete de Machine Learning non supervisee** appliquee a la consommation electrique residentielle, depuis le nettoyage des donnees brutes jusqu'a la detection automatisee d'anomalies.

La **segmentation K-Means (k = 4)** revele quatre profils de consommation distincts : faible, moderee, moyenne, et forte/instable. Ce dernier cluster concentre la majorite des anomalies detectees et constitue la zone de risque prioritaire.

L'**Isolation Forest** identifie **72 journees atypiques (~5%)** sur les 1 433 analysees. L'analyse comparative du 16 vs 17 decembre 2006 valide visuellement la pertinence du modele : le jour suspect presente

clairement une signature anormale que l'algorithme capture efficacement.

Etape	Action	Outil
1. Data Cleaning	Valeurs manquantes, types, index temporel	<i>pandas</i>
2. Feature Engineering	Agregation journaliere, 8 variables	<i>pandas</i> / <i>resample</i>
3. Normalisation	StandardScaler - moyenne=0, std=1	<i>sklearn</i>
4. K-Means (k=4)	Segmentation en 4 profils de consommation	<i>sklearn</i>
5. Isolation Forest	Detection de 72 jours suspects (~5%)	<i>sklearn</i>

Ce travail constitue une **base solide** pour le deploiement d'un systeme de detection automatique en production. Les ameliorations identifiees - variables temporelles, donnees meteo, indicateurs avances - permettraient de reduire significativement les faux positifs et d'affiner la fiabilite du systeme.